

Introducción

La asimilación de datos consiste en reconstruir el estado inicial de un sistema dinámico a partir de una secuencia de observaciones ruidosas distribuidas a lo largo de una ventana temporal. Esta es la tarea que resuelven los métodos de asimilación variacional —3D-Var y 4D-Var— desarrollados originalmente en meteorología y oceanografía, y hoy aplicados también en epidemiología, glaciología, sismología y modelado de calidad del aire. En este proyecto implementaremos 4D-Var sobre un modelo sencillo pero suficientemente rico para exhibir todos los ingredientes del método: ecuación forward no lineal, ecuación adjunta lineal retrógrada, gradiente reducido, y término de background con covarianza.

1. Modelo dinámico

La dinámica del estado $x(t)$ está gobernada por la ecuación logística

$$\frac{dx}{dt} = rx \left(1 - \frac{x}{K}\right), \quad t \in [0, T], \quad (1)$$

con condición inicial

$$x(0) = X_0, \quad (2)$$

donde los parámetros $r > 0$ y $K > 0$ se suponen conocidos y la incógnita es el estado inicial X_0 . Para hacer explícita la dependencia del control, denotamos por $x(t; X_0)$ la solución de (1)–(2), y abreviamos $x^\dagger(t) := x(t; X_0^\dagger)$ para la trayectoria verdadera. Disponemos de N observaciones ruidosas

$$y_i = x^\dagger(t_i) + \eta_i, \quad \eta_i \sim \mathcal{N}(0, \sigma^2), \quad i = 1, \dots, N, \quad (3)$$

en tiempos $0 < t_1 < \dots < t_N \leq T$ distribuidos a lo largo de la ventana de asimilación $[0, T]$. Adicionalmente contamos con un valor de background X_0^b —una estimación previa de la condición inicial— con incertidumbre caracterizada por la varianza $B > 0$.

2. Funcional 4D-Var

El método 4D-Var formula la asimilación como el problema de optimización

$$\min_{X_0 \in \mathbb{R}} J(X_0) = \underbrace{\frac{1}{2B}(X_0 - X_0^b)^2}_{\text{término de background } J_b} + \underbrace{\frac{1}{2\sigma^2} \sum_{i=1}^N (x(t_i; X_0) - y_i)^2}_{\text{término de observaciones } J_o} \quad (4)$$

sujeto a la restricción dinámica (1)–(2). La solución $\hat{X}_0$ de (4) es el análisis; la trayectoria $x(t; \hat{X}_0)$ obtenida al integrar el modelo desde $\hat{X}_0$ es el análisis 4D. Bayesianamente, $\hat{X}_0$ es el estimador de máximo a posteriori bajo verosimilitud gaussiana de los errores y prior gaussiana $X_0 \sim \mathcal{N}(X_0^b, B)$.

2.1. Sobre la dimensión

Aunque en este proyecto el estado es escalar ($x(t) \in \mathbb{R}$) y por tanto la covarianza B es también escalar, todo el formalismo aquí desarrollado es idéntico al caso vectorial, donde $x(t) \in \mathbb{R}^n$, $B \in \mathbb{R}^{n \times n}$ es una matriz simétrica positiva definida, y la ecuación adjunta es un sistema de EDOs lineales retrógradas. Toda la maquinaria del adjunto escala al caso vectorial sin cambios estructurales.

3. Marco teórico

El problema (4) es una instancia del esquema general del Corolario 3.56 del tutorial de Bui-Thanh (2023), con variable de control X_0 y restricción dada por la EDO. El gradiente dJ/dX_0 se calcula vía el Lagrangiano

$$\mathcal{L}(x, X_0, \lambda) = J(X_0) + \int_0^T \lambda(t) [\dot{x} - rx(1 - x/K)] dt + \mu(x(0) - X_0), \quad (5)$$

donde $\lambda(t)$ es el multiplicador para la EDO y $\mu \in \mathbb{R}$ para la condición inicial.

4. Datos del problema

Los parámetros son como se indica en la siguiente tabla:

Nombre	Significado	Valor
r	Tasa de crecimiento (conocida)	1.0
K	Capacidad de carga (conocida)	100
T	Horizonte / ventana de asimilación	5
$X_0^\dagger$	Estado inicial verdadero (oculto)	10
X_0^b	Estado inicial background	por elegir
B	Varianza del background	por elegir
N	Número de observaciones en $[0, T]$	10
σ	Desviación estándar del ruido	$0.05 \cdot \max_{t \in [0, T]} x^\dagger(t)$
τ_k	Paso de descenso en iteración k	búsqueda de línea

Observación importante sobre la ventana. Se sugiere $T = 5$. Con $r = 1$ y $X_0^\dagger = 10$, el sistema satura en $t \approx 7$; tomar la ventana hasta $t = 5$ asegura que las observaciones contengan información sobre la fase de crecimiento, donde X_0 es realmente identificable. Discute en tu reporte qué ocurre si se toma T demasiado grande (saturación) o demasiado pequeño (poca información).

5. Resolución del problema de asimilación 4D-Var

5.1. 1. Deducción de la ecuación adjunta

Partiendo del Lagrangiano (5), calcula la variación $\langle \partial \mathcal{L} / \partial x, h \rangle$ en una dirección arbitraria $h(t)$ con $h(0)$ libre, integra por partes y anula la variación. Obtén la ecuación adjunta

$$-\dot{\lambda} - r \left(1 - \frac{2x(t; X_0)}{K} \right) \lambda = -\frac{1}{\sigma^2} \sum_{i=1}^N (x(t_i; X_0) - y_i) \delta(t - t_i), \quad \lambda(T) = 0, \quad (6)$$

junto con la condición de transversalidad $\mu = \lambda(0)$ que relaciona el multiplicador de la EDO con el de la condición inicial. Aquí $x(t; X_0)$ es la solución forward para el valor actual del control, es decir, el coeficiente de la EDO adjunta depende de la trayectoria forward y debe almacenarse durante la simulación del problema directo.

Solución. El funcional es:

$$J(X_0) = \frac{1}{2B} (X_0 - X_0^b)^2 + \frac{1}{2\sigma^2} \sum_{i=1}^N (x(t_i; X_0) - y_i)^2$$

Tenemos como Lagrangiano:

$$\mathcal{L}(x, X_0, \lambda) = J(X_0) + \int_0^T \lambda(t) [\dot{x} - rx(1 - x/K)] dt + \mu(x(0) - X_0),$$

sabemos que minimizar tiene que cumplir que: $\nabla J = \nabla \mathcal{L}$ entonces la derivada direccional de J es:

$$\begin{aligned} DJ(X_0)h &= D\mathcal{L}(x, X_0)(\xi, h) \\ &= D_x \mathcal{L} \xi + D_{X_0} \mathcal{L} h \end{aligned}$$

Lo anterior es válido porque en el punto estacionario las variaciones respecto a λ se anulan (recuperan la ecuación forward), de modo que $D\mathcal{L}$ colapsa a DJ .

derivando respecto a x :

$$D_x \mathcal{L} \xi = \frac{1}{\sigma^2} \sum_{i=1}^N (x(t_i) - y_i) \xi(t_i) + \int_0^T \lambda(t) \left[\dot{\xi} - r \left(1 - \frac{2x}{K} \right) \xi \right] dt + \mu \xi(0),$$

intercambiar el diferencial con la integral es válido por la regularidad de λ y ξ .

derivando respecto a X_0 :

$$D_{X_0} \mathcal{L} h = \frac{1}{B} (X_0 - X_0^b) h - \mu h,$$

nos interesa que $D_x \mathcal{L} \xi = 0$, para ello trabajamos el término:

$$\int_0^T \lambda(t) \left[\dot{\xi} - r \left(1 - \frac{2x}{K} \right) \xi \right] dt$$

usando la regla del producto en $\lambda(t)\dot{\xi}$:

$$\frac{d}{dt}(\lambda \xi) = \dot{\lambda} \xi + \lambda \dot{\xi} \implies \lambda \dot{\xi} = \frac{d}{dt}(\lambda \xi) - \dot{\lambda} \xi$$

entonces la integral queda:

$$\int_0^T \frac{d}{dt}(\lambda \xi) - \dot{\lambda} \xi - r \left(1 - \frac{2x}{K}\right) \lambda \xi dt$$

evaluando el término de frontera:

$$\int_0^T \frac{d}{dt}(\lambda \xi) dt = \lambda(T)\xi(T) - \lambda(0)\xi(0) = -\lambda(0)\xi(0)$$

donde usamos $\lambda(T) = 0$. Sustituyendo en $D_x \mathcal{L} \xi = 0$:

$$\frac{1}{\sigma^2} \sum_{i=1}^N (x(t_i) - y_i) \xi(t_i) + \int_0^T \left[-\dot{\lambda} - r \left(1 - \frac{2x}{K}\right) \lambda \right] \xi dt + (\mu - \lambda(0)) \xi(0) = 0,$$

como $\xi(0)$ es libre, para que esto se anule para toda dirección ξ el coeficiente de $\xi(0)$ debe ser cero:

$$\mu = \lambda(0) \quad (\text{condición de transversalidad})$$

cancelado ese término, usando que $\xi(t_i) = \int_0^T \xi(t) \delta(t - t_i) dt$, la condición debe valer para todo ξ , lo que implica la igualdad puntual:

$$-\dot{\lambda} - r \left(1 - \frac{2x}{K}\right) \lambda = -\frac{1}{\sigma^2} \sum_{i=1}^N (x(t_i) - y_i) \delta(t - t_i)$$

hemos deducido la ecuación adjunta con condición terminal $\lambda(T) = 0$. ■

5.2. 2. Deducción del gradiente reducido

Varía $\mathcal{L}$ respecto a X_0 , usa que x, λ satisfacen las ecuaciones forward y adjunta, y deduce

$$\frac{dJ}{dX_0} = \frac{X_0 - X_0^b}{B} - \lambda(0). \quad (7)$$

Comenta el significado: el gradiente es la suma de un tirón hacia el background (primer término) y la sensibilidad retrógrada de las observaciones al estado inicial (segundo término, $\lambda(0)$). Esto justifica llamar al adjunto el “transportador hacia atrás de la información de las observaciones”.

Solución. Variamos $\mathcal{L}$ respecto a X_0 en una dirección h :

$$D_{X_0} \mathcal{L} h = \frac{1}{B} (X_0 - X_0^b) h - \mu h$$

como x y λ satisfacen las ecuaciones forward y adjunta, esta variación coincide con $DJ(X_0)h$, entonces:

$$\frac{dJ}{dX_0} h = \frac{1}{B} (X_0 - X_0^b) h - \mu h$$

sustituyendo la condición de transversalidad $\mu = \lambda(0)$ obtenida en el punto anterior:

$$\boxed{\frac{dJ}{dX_0} = \frac{X_0 - X_0^b}{B} - \lambda(0)}$$

El primer término jala la solución hacia el background; el segundo, $-\lambda(0)$, transporta hacia atrás la información de las observaciones a través de la ecuación adjunta.

El gradiente tiene una interpretación clara: si se busca minimizar J , el término $\frac{X_0 - X_0^b}{B}$ empuja a X_0 hacia el background X_0^b , pues se anula exactamente cuando $X_0 = X_0^b$. Por otro lado, $\lambda(0)$ es la solución en $t = 0$ de la ecuación adjunta (6), que es una EDO lineal de primer orden no homogénea retrógrada en $[0, T]$: su término forzante son las discrepancias $(x(t_i; X_0) - y_i)$ en los tiempos de observación, y al integrar de T hacia 0 propaga esa información hasta el estado inicial. De ahí que $-\lambda(0)$ mida la sensibilidad acumulada de todas las observaciones respecto a X_0 , jalando el análisis hacia donde los datos son más consistentes. ■

5.3. 3. Generación de datos sintéticos (twin experiment)

Adopta el protocolo estándar de validación 4D-Var:

- (a) Integra (1) con $X_0^\dagger = 10$ usando RK4 sobre $[0, 5]$; solution

Muestra $N = 10$ observaciones en tiempos equiespaciados $t_i = 0.5 i$ para $i = 1, \dots, 10$;

Añade ruido gaussiano con $\sigma = 0.05 \cdot \max_{t \in [0, T]} x^\dagger(t)$.

La trayectoria verdadera te servirá únicamente como referencia para medir el error del análisis; el algoritmo nunca la verá.

5.4. 4. Implementación forward

Implementa un integrador RK4 para (1) que reciba X_0 y devuelva la trayectoria $x(t; X_0)$ sobre una malla densa que contenga los t_i . Almacena la trayectoria; el adjunto la necesitará como coeficiente.

5.5. 5. Implementación del adjunto

Implementa la integración retrógrada de (6) de T a 0, partiendo de $\lambda(T) = 0$. Al cruzar cada t_i de derecha a izquierda, incorpora el salto

$$\lambda(t_i^-) = \lambda(t_i^+) + \frac{1}{\sigma^2}(x(t_i; X_0) - y_i).$$

Verifica con cuidado la consistencia de signos. El signo del salto se obtiene integrando la δ de Dirac de la ecuación adjunta (6) sobre un entorno $[t_i - \epsilon, t_i + \epsilon]$ y haciendo $\epsilon \rightarrow 0$; con la convención de signos de (6) y la integración de T hacia 0, el incremento $\lambda(t_i^-) - \lambda(t_i^+)$ es positivo cuando $x(t_i; X_0) > y_i$. Un error de signo aquí es la causa más frecuente de fallo del test de Taylor (punto siguiente). Devuelve $\lambda(0)$ y, con él, ensambla el gradiente (7).

5.6. 6. Test de Taylor (opcional)

Antes de optimizar, valida tu gradiente. Para una dirección $\delta X_0 \in \mathbb{R}$ arbitraria y para $\varepsilon \in \{10^{-1}, 10^{-2}, \dots, 10^{-8}\}$ calcula

$$E_1(\varepsilon) = |J(X_0 + \varepsilon \delta X_0) - J(X_0)|, \quad E_2(\varepsilon) = |J(X_0 + \varepsilon \delta X_0) - (J(X_0) + \varepsilon \left(\frac{dJ}{dX_0} \right) \delta X_0)|.$$

E_1 debe decaer con pendiente 1 y E_2 con pendiente 2 en gráfica log-log, ambos sobre al menos cuatro órdenes de magnitud. Si la pendiente de E_2 no es 2, el adjunto está mal y debes corregirlo antes de continuar.

5.7. 7. Minimización 4D-Var

Implementa descenso más pronunciado con búsqueda de línea de Armijo:

- (a) Resolver forward con $X_0^{(k)}$ para obtener $x_k(t)$;
- (b) Resolver adjunto para obtener $\lambda_k(0)$;
- (c) Ensamblar el gradiente (7);
- (d) Línea de búsqueda y actualizar $X_0^{(k+1)} = X_0^{(k)} - \tau_k \frac{dJ}{dX_0}$.

Inicializa con $X_0^{(0)} = X_0^b$ (el background). Reporta la convergencia de $J(X_0^{(k)})$, $|dJ/dX_0|$ y $|X_0^{(k)} - X_0^\dagger|$.

5.8. 8. Estudio del peso relativo background/observaciones

Realiza tres experimentos de asimilación variando la confianza relativa entre el background y las observaciones, manteniendo $X_0^b = 5$ (lejos del valor verdadero 10):

- (a) Background dominante: $B = 0.1$, σ como en la tabla;
- (b) Equilibrio: $B = 10$;
- (c) Observaciones dominantes: $B = 10^4$.

En cada caso reporta el análisis $\hat{X}_0$ y compáralo con $X_0^\dagger = 10$ y con $X_0^b = 5$. Discute cómo B controla el compromiso entre confiar en el prior y confiar en los datos.

6. Entregables

- (a) Reporte en PDF (máximo 12 páginas) con las deducciones de los puntos 1-2, la figura obligatoria del test de Taylor (punto 6), y los experimentos de los puntos 7-11.
- (b) Código reproducible (Python, Julia o MATLAB) con un README que permita regenerar todas las figuras del reporte.

Referencias sugeridas

- Bui-Thanh, T. (2023). Adjoint and Its roles in Sciences, Engineering, and Mathematics: A Tutorial. arXiv:2306.09917. Secciones 3.5-3.6.
- Asch, M., Bocquet, M., Nodet, M. (2016). Data Assimilation: Methods, Algorithms, and Applications. SIAM. Capítulos 2 y 4.

- Lewis, J.M., Lakshmivarahan, S., Dhall, S. (2006). Dynamic Data Assimilation: A Least Squares Approach. Cambridge University Press.
- Le Dimet, F.-X., Talagrand, O. (1986). Variational algorithms for analysis and assimilation of meteorological observations. Tellus A, 38(2), 97-110. (Artículo fundacional de 4D-Var.)