

Ecuación de Poisson

Consideremos el problema de valores a la frontera para la ecuación de Poisson

$$-u''(x) = f(x), \quad x \in (0, L), \quad u(0) = u(L) = 0. \quad (1)$$

La solución se puede escribir como una integral usando la función de Green $G(x, \xi)$:

$$u(x) = \int_0^L G(x, \xi) f(\xi) d\xi,$$

donde la función de Green está dada por:

$$G(x, \xi) = \begin{cases} \frac{x(L - \xi)}{L}, & \text{si } x \leq \xi, \\ \frac{\xi(L - x)}{L}, & \text{si } x > \xi. \end{cases}$$

Entonces, la solución general del problema es:

$$u(x) = \int_0^x \frac{\xi(L - x)}{L} f(\xi) d\xi + \int_x^L \frac{x(L - \xi)}{L} f(\xi) d\xi. \quad (2)$$

Ejercicios

1. Implementa la cuadratura de la regla del punto medio compuesta para discretizar el problema (2) suponiendo que $L = 1$.

Solución. Definimos el paso de discretización h como

$$h = \frac{1}{n}$$

donde n es el número de subintervalos. La cuadratura de la regla del punto medio compuesta está definida como

$$\xi_i^* = \left(i - \frac{1}{2}\right) h, \quad i = 1, \dots, n$$

donde ξ_i^* son los puntos de evaluación para $f(\xi)$, y la integral se aproxima por

$$\int_0^1 g(\xi) d\xi \approx h \sum_{i=1}^n g(\xi_i^*)$$

Aplicando esto a la ecuación (2) con $L = 1$:

$$u(x) = \int_0^x \xi(1 - x) f(\xi) d\xi + \int_x^1 x(1 - \xi) f(\xi) d\xi$$

Discretizando:

$$u(x) \approx h \sum_{i: \xi_i^* \leq x} \xi_i^* (1 - x) f(\xi_i^*) + h \sum_{i: \xi_i^* > x} x (1 - \xi_i^*) f(\xi_i^*)$$

Si consideramos un conjunto de puntos de observación x_j para $j = 1, \dots, m$, entonces:

$$u(x_j) \approx h \sum_{i=1}^n G(x_j, \xi_i^*) f(\xi_i^*)$$

donde

$$G(x_j, \xi_i^*) = \begin{cases} \xi_i^* (1 - x_j), & \text{si } x_j \leq \xi_i^* \\ x_j (1 - \xi_i^*), & \text{si } x_j > \xi_i^* \end{cases}$$

Esto se puede escribir como un sistema lineal:

$$\mathbf{u} \approx A\mathbf{f}$$

donde $\mathbf{u} \in \mathbb{R}^m$, $\mathbf{f} \in \mathbb{R}^n$, y la matriz $A \in \mathbb{R}^{m \times n}$ tiene elementos:

$$[A]_{ji} = h \begin{cases} \xi_i^* (1 - x_j), & x_j \leq \xi_i^* \\ x_j (1 - \xi_i^*), & x_j > \xi_i^* \end{cases}$$

■

2. Haz un modelo a priori de $f(x)$ mediante un Gaussian Markov Random Field usando el artículo de Bardsley como referencia. Considera que la condición de frontera de f es conocida. Nota: Al construir la distribución a priori, es necesario añadir un offset (desplazamiento) a la media; de lo contrario, la media a priori será cero y el modelo no capturará adecuadamente la información disponible sobre f .

Solución. Se puede considerar que es un problema inverso lineal:

$$b = Ax + \eta$$

donde $b \in \mathbb{R}^m$ son los datos observados, $x \in \mathbb{R}^n$ es el vector desconocido, $A \in \mathbb{R}^{m \times n}$ es la matriz del modelo, y η es ruido gaussiano.

La verosimilitud está dada por:

$$p(b|x) \propto \exp \left(-\frac{\lambda}{2} \|Ax - b\|^2 \right)$$

donde $\lambda = 1/\sigma^2$ es la precisión del ruido.

Para el prior, consideramos un GMRF con media μ :

$$p(x) \propto \exp \left(-\frac{1}{2} (x - \mu)^T Q (x - \mu) \right)$$

donde Q es la matriz de precisión. En una malla uniforme con paso h , para un GMRF de primer orden:

$$[Q]_{ij} = \frac{\delta}{h^2} \begin{cases} n_i, & i = j \\ -1, & j \in \partial_i \\ 0, & \text{en otro caso} \end{cases}$$

donde ∂_i son los vecinos del nodo i , $n_i = |\partial_i|$ es el número de vecinos, y $\delta > 0$ es un parámetro de regularización.

Para puntos interiores: $n_i = 2$, $Q_{ii} = 2\delta/h^2$, $Q_{i,i\pm 1} = -\delta/h^2$. Para puntos en la frontera: $n_i = 1$, $Q_{ii} = \delta/h^2$, y solo un vecino.

La distribución posterior es:

$$p(x|b) \propto p(b|x)p(x) \propto \exp\left(-\frac{1}{2}(x - \mu_{\text{post}})^T \Sigma_{\text{post}}^{-1}(x - \mu_{\text{post}})\right)$$

■

3. Implementa la solución bayesiana del problema inverso de determinar

$$f(x) = x$$

dadas observaciones ruidosas de

$$u(x) = \frac{1}{6}x(1-x)(1+x)$$

con ruido aditivo gaussiano con relación de señal a ruido 100.

4. Calcula la media y la covarianza posterior de forma analítica.

Solución. Consideramos que

$$x|b \sim \mathcal{N}(\mu_{\text{post}}, \Sigma_{\text{post}})$$

entonces $p(x|b)$ es

$$p(x|b) = \frac{1}{(2\pi)^{n/2} |\Sigma_{\text{post}}|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu_{\text{post}})^T \Sigma_{\text{post}}^{-1}(x - \mu_{\text{post}})\right)$$

de su forma logarítmica

$$\log p(x|b) = -\frac{n}{2} \log(2\pi) - \frac{1}{2} \log |\Sigma_{\text{post}}| - \frac{1}{2} (x - \mu_{\text{post}})^T \Sigma_{\text{post}}^{-1} (x - \mu_{\text{post}})$$

si conocemos la proporción de $\log p(x|b)$

$$\begin{aligned} \log p(x|b) &\propto \log p(b|x) + \log p(x) \\ &\propto -\frac{\lambda}{2} \|Ax - b\|^2 - \frac{n}{2} \log(2\pi) + \frac{1}{2} \log |Q| - \frac{1}{2} (x - \mu)^T Q (x - \mu) \end{aligned}$$

haciendo un reacomodo algebraico

$$\log p(x|b) \propto -\frac{n}{2} \log(2\pi) + \frac{1}{2} \log |Q| - \frac{\lambda}{2} \langle Ax - b, Ax - b \rangle - \frac{1}{2} \langle x - \mu, Q(x - \mu) \rangle$$

la parte de interés es

$$\begin{aligned} &= -\frac{\lambda}{2} \langle Ax - b, Ax - b \rangle - \frac{1}{2} \langle x - \mu, Q(x - \mu) \rangle \\ &= -\frac{\lambda}{2} (\langle Ax, Ax \rangle - \langle Ax, b \rangle - \langle b, Ax \rangle + \langle b, b \rangle) - \frac{1}{2} (\langle x, Q(x - \mu) \rangle - \langle \mu, Q(x - \mu) \rangle) \\ &= -\frac{\lambda}{2} (x^T A^T A x - x^T A^T b - b^T A x + b^T b) - \frac{1}{2} (x^T Q x - x^T Q \mu - \mu^T Q x + \mu^T Q \mu) \end{aligned}$$

como Q es simétrica entonces $-x^T Q \mu - \mu^T Q x = -2x^T Q \mu$

$$= -\frac{1}{2} x^T (\lambda A^T A + Q) x + (\lambda b^T A + \mu^T Q) x - \frac{\lambda}{2} b^T b - \frac{1}{2} \mu^T Q \mu$$

Esta expresión es una forma cuadrática en x :

$$\log p(x|b) \propto -\frac{1}{2} x^T (\lambda A^T A + Q) x + (\lambda b^T A + \mu^T Q) x + \text{constante}$$

Comparando con la forma cuadrática de una distribución normal:

$$-\frac{1}{2} (x - \mu_{\text{post}})^T \Sigma_{\text{post}}^{-1} (x - \mu_{\text{post}}) = -\frac{1}{2} x^T \Sigma_{\text{post}}^{-1} x + \mu_{\text{post}}^T \Sigma_{\text{post}}^{-1} x + \text{constante}$$

Identificamos:

$$\begin{aligned} \Sigma_{\text{post}}^{-1} &= \lambda A^T A + Q \\ \mu_{\text{post}}^T \Sigma_{\text{post}}^{-1} &= \lambda b^T A + \mu^T Q \end{aligned}$$

Por lo tanto:

$$\begin{aligned} \Sigma_{\text{post}} &= (\lambda A^T A + Q)^{-1} \\ \mu_{\text{post}} &= \Sigma_{\text{post}} (\lambda A^T b + Q \mu) \end{aligned}$$

Muestra tu distribución posterior y compara la media posterior numérica tomando en cuenta el tiempo integrado de autocorrelación.




Figura 0.1: Resultados punto 3,4,5

5. Calcula la constante de normalización de manera analítica, y numéricamente de la manera siguiente:

(a) Usa la función `scipy.stats.gaussian_kde` para ajustar una distribución gaussiana $G(f)$ a las muestras que obtuviste.

(b) Aproxima

$$\begin{aligned} z_0 &= \int \pi(u|f)\pi(f) df \\ &= \int \frac{\pi(u|f)\pi(f)}{G(f)} G(f) df \\ &\approx \frac{1}{N} \sum_{j=1}^N \frac{\pi(u|f_j)\pi(f_j)}{G(f_j)} \end{aligned}$$

donde $\{f_j\}_{j=1}^N$ son muestras de $G(f)$.

Solución.

■

El Truco del Log-Sum-Exp: Una Herramienta para la Estabilidad Numérica

Motivación

En muchos cálculos probabilísticos, frecuentemente nos encontramos con expresiones del tipo:

$$\log \left(\sum_{i=1}^N e^{a_i} \right)$$

Esta expresión aparece naturalmente al calcular el logaritmo de una mezcla, log-verosimilitud de modelos marginales, y en particular al estimar esperanzas en espacio logarítmico como:

$$\log \left(\frac{1}{N} \sum_{i=1}^N w_i \right) = \log \left(\frac{1}{N} \sum_{i=1}^N e^{\log w_i} \right)$$

El cálculo directo de esta cantidad puede sufrir de inestabilidad numérica debido a desbordamientos (overflow) o subdesbordamientos (underflow) cuando los exponentes a_i son muy positivos o muy negativos.

El Truco

Sean $a_1, a_2, \dots, a_N \in \mathbb{R}$. Definimos:

$$M = \max_i a_i$$

Entonces:

$$\log \left(\sum_{i=1}^N e^{a_i} \right) = M + \log \left(\sum_{i=1}^N e^{a_i - M} \right)$$

¿Por qué Funciona?

Dado que $a_i - M \leq 0$, los exponenciales $e^{a_i - M}$ son todos menores o iguales a 1, evitando desbordamientos. Además, si los a_i son muy negativos, restar M lleva el mayor término a cero, evitando subdesbordamientos en los otros términos.

Ejemplo

Supongamos:

$$a = [-1000, -1001, -999]$$

Entonces:

$$\sum_{i=1}^3 e^{a_i} = e^{-1000} + e^{-1001} + e^{-999}$$

Estos números son demasiado pequeños para ser representados en punto flotante estándar. Usando el truco:

$$\log \left(\sum_{i=1}^3 e^{a_i} \right) = -999 + \log \left(e^{-1} + e^{-2} + 1 \right) \approx -999 + \log \left(1 + e^{-1} + e^{-2} \right)$$

En la Práctica

En Python (por ejemplo, usando NumPy), esto se implementa como:

```
def logsumexp(a):
    a_max = np.max(a)
    return a_max + np.log(np.sum(np.exp(a - a_max)))
```

Muchas bibliotecas científicas como `scipy` y `PyTorch` también implementan una función estable llamada `logsumexp`.